

Predição de curvas epidêmicas

COVID-19 em SP: da análise clássica (**decomposição, ACF/PACF, SARIMA**) à modelagem automática com **LazyPredict**.

séries temporais · análise
no Colab · LazyPredict

o problema

Quantos casos teremos nas **próximas 4 semanas**?

Essa resposta decide **leitos de UTI**, oxigênio, insumos e escala de equipes. Prever cedo é **se preparar**; errar é hospital lotado — ou recurso caríssimo jogado fora.

UTI & leitos

oxigênio
& insumos

escala de equipes

afrouxar / apertar

■ a curva que precisamos prever

5,23
mi


casos confirmados

167
mil

óbitos

37.611

pico em 1 dia



São Paulo, 2020–2022. Três ondas e um serrilhado semanal — difícil de prever no olho.

os dados · escala big data

3,85 milhões de registros brutos.

18

colunas

5.570

municípios BR

92 MB

comprimido

762

dias (SP)

Fonte oficial **DataSUS** / **Brasil.IO** (25/02/2020 a 27/03/2022). A matéria-prima é grande; o desafio é **tratá-la** até virar uma série diária utilizável.

■ tratamento dos dados


► ao vivo no Colab

1. Ler só **6 de 18 colunas** — eficiência de memória com dado grande.
2. Filtrar o **nível estadual de SP** (já é a soma diária de todos os municípios).
3. Garantir **frequência diária contínua** (sem buracos no calendário).
4. **Zerar valores negativos** das correções retroativas do governo.
5. Converter tipos e ordenar → **série diária de 762 dias**.

Honestidade: para SP a série já vinha íntegra — **0 datas faltando e 0 negativos**. As travas existem (código robusto para qualquer estado), mas nada precisou ser corrigido.

▬ distribuição dos dados

► ao vivo no Colab



A distribuição dos casos é **muito assimétrica** (muitos dias baixos, poucos picos). Em **escala log** ela se equilibra — por isso modelamos em $\log(1+\text{casos})$.


■ sazonalidade semanal · o dado é sujo

Fim de semana quase não testa.

A curva **serrilha toda semana**: domingo registra metade da média; quinta, quase 40% acima. Não é a epidemia — é o *cartório*, criando **sazonalidade de período 7**.


domingo $\approx 0,49 \times$ | quinta $\approx 1,38 \times$

► ao vivo no Colab



análise de série temporal

► ao vivo no Colab




Decomposição: série (log) = **tendência** (as ondas) + **sazonalidade semanal** + resíduo.

Estacionariedade (ADF/KPSS): em nível divergem; após **1 diferença** estaciona $\Rightarrow d = 1$.

ACF/PACF: picos em **7, 14, 21** confirmam o ciclo semanal $\Rightarrow$ pede **SARIMA**.


treino + teste (no tempo)

► ao vivo no Colab



Treino = tudo até **31/10/2021** (601 dias); teste = os **28 dias seguintes** (nov/2021). O teste vem **sempre depois** do treino (senão é vazamento). **Todos** os modelos usam esta mesma divisão.

modelos clássicos de série temporal



A sazonalidade é o que mais reduz o erro.

▶ **Holt-Winters** e **SARIMA** aprendem o ciclo de 7 dias e reproduzem o zigue-zague; o **ARIMA** prevê quase uma linha plana.

Modelo	RMSE
Holt-Winters	498
SARIMA	567
Naïve sazonal	652
ARIMA	714

alternativa automática: série → tabela

▶ ao vivo no Colab

E se a máquina escolhesse o modelo? Primeiro viramos a série numa **tabela**: para prever **hoje**, as pistas são o passado dela.

Série temporal vira uma tabela comum: prever HOJE a partir do passado

data	casos hoje	ontem	7 dias atrás	média 7d	é quinta?
19/04	373	1,053	336	782	—
20/04	313	373	140	787	—
21/04	805	313	476	812	—
22/04	529	805	1,672	859	—
23/04	826	529	525	696	sim
24/04	1,086	826	1,273	739	—
25/04	2,178	1,086	1,053	712	—
26/04	711	2,178	373	873	—

Pistas: ontem, 7 dias atrás, média da semana, dia da semana → casos de hoje. Vira **748 linhas × 15 pistas**. Sem “colar”: toda pista usa só o passado.

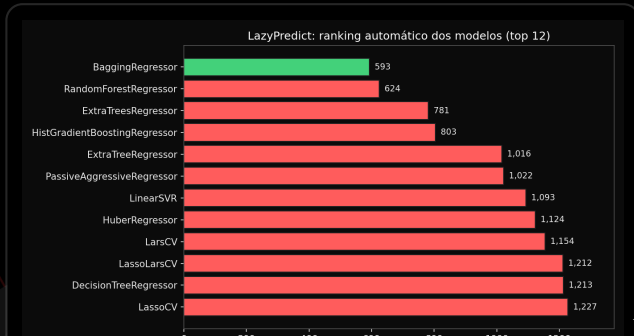
■ a mágica: LazyPredict

► ao vivo no Colab

```
# ferramenta sugerida pelo professor:  
from lazypredict.Supervised import LazyRegressor  
modelos, _ = LazyRegressor().fit(X_tr, X_te, y_tr, y_te)
```


39 modelos treinados e
ranqueados sozinhos.

Em segundos, sem escolher nada à
mão.



comparação geral

► ao vivo no Colab



Na mesma janela, o **Holt-Winters** (sazonal, à mão) vence; o **LazyPredict** (593) chega competitivo com **uma linha**. Nota: LazyPredict é avaliado um-passo-à-frente — tarefa mais fácil que os 28 dias dos

conclusões

1. **É um problema de série temporal.** Decomposição, ADF/KPSS e ACF/PACF revelaram a sazonalidade semanal (período 7) da notificação.
2. **Quem capta a sazonalidade vence.** Holt-Winters e SARIMA batem folgado o ARIMA (linha plana) e o naïve.
3. **LazyPredict é o atalho.** Em uma linha, testou dezenas de modelos e chegou perto dos clássicos. Automatizar acha o candidato; *conhecer a série* dá o melhor resultado.

Obrigado! · Perguntas?