

EpiCurveAnalyzer

Séries Temporais: da Regressão Linear ao SARIMAX

Allan Vasconcelos

Universidade Federal da Paraíba (UFPB) – Seminário de Séries Temporais – 2026

■ Roteiro

Introdução aos modelos de séries temporais

Análise exploratória e estacionariedade

Regressão linear simples

Alisamento exponencial

Autocorrelação: ACF e PACF

Modelos de médias móveis (MA)

Modelos autorregressivos (AR)

Modelos ARMA

Modelos ARIMA

Sazonalidade: SARMA e SARIMA

Variáveis exógenas: SARIMAX

Comparação e conclusões



Introdução aos modelos de séries temporais

0 que é uma série temporal?

Definição

Uma **série temporal** é uma sequência de observações de uma variável indexadas no tempo e **ordenadas cronologicamente**:

$$\{y_t\}_{t=1}^n = y_1, y_2, \dots, y_n.$$

A característica essencial é a **dependência temporal**: observações próximas tendem a ser correlacionadas — o que **viola** a hipótese de independência da estatística clássica.

- ▶ **Exemplos**: casos diários de uma doença, PIB, temperatura, ações.
- ▶ **Objetivos**: descrever, explicar a estrutura e, sobretudo, **prever** ($\hat{y}_{n+h}$).

Componentes de uma série temporal

$$y_t = \underbrace{T_t}_{\text{tendência}} + \underbrace{S_t}_{\text{sazonal}} + \underbrace{C_t}_{\text{ciclo}} + \underbrace{\varepsilon_t}_{\text{ruído}} \quad (\text{aditiva}); \quad y_t = \underbrace{T_t}_{\text{tendência}} \cdot \underbrace{S_t}_{\text{sazonal}} \cdot \underbrace{\varepsilon_t}_{\text{ruído}} \quad (\text{multiplicativa})$$

Tendência T_t : movimento de longo prazo.

Sazonalidade S_t : padrão que se repete em período fixo s .

Ciclo C_t : oscilações de período não fixo (ondas).

Irregular ε_t : ruído aleatório.

A forma multiplicativa vira aditiva no **logaritmo**: $\log y_t = \log T_t + \log S_t + \log \varepsilon_t$.

■ Três abordagens – o fio condutor

1. **Decomposição / Regressão** — modela tendência e sazonalidade explicitamente. *Partimos da regressão linear simples.*
2. **Alisamento exponencial** — médias com pesos que decaem (SES, Holt, Holt-Winters).
3. **Box–Jenkins (ARIMA)** — modela diretamente a **autocorrelação**: AR, MA, ARMA, ARIMA, SARIMA, SARIMAX.


Estudo de caso: aplicaremos **todos** esses modelos aos **casos diários de COVID-19 em São Paulo**.


Estudo de caso: COVID-19 em São Paulo

Fonte: DataSUS / Brasil.IO
(caso_full.csv.gz).

- ▶ $\approx 3,85$ mi de registros municipais.
- ▶ Recorte: **estado de SP** (agregado).
- ▶ **25/02/2020 a 27/03/2022**; $n = 762$ dias.
- ▶ 5,23 mi de casos; 167 mil óbitos.
- ▶ Pico: **37.611 casos** (03/02/2022).


Série diária $\Rightarrow$ **sazonalidade semanal** ($s = 7$).



The background of the slide is black and features several stylized virus particles. These particles are represented as dark gray circles with numerous small red dots protruding from their perimeters, resembling spikes or surface proteins. They are scattered across the frame, with some appearing larger and more prominent than others.

--- Análise exploratória e estacionariedade ---

■ Sazonalidade semanal: o efeito da notificação




Quedas sistemáticas nos fins de semana: menos testagem/registo, com represamento divulgado na semana seguinte.

$$\text{domingo} \approx 0,49 \times \overline{\text{média}}$$

$$\text{quinta} \approx 1,38 \times \overline{\text{média}}$$


Sazonalidade do **processo de medição**, não da epidemia.

■ Perfil sazonal por dia da semana



Fator multiplicativo médio (1,0 = média semanal): segunda e domingo concentram a subnotificação.

Decomposição da série



Decomposição aditiva de $\log(1 + \text{casos})$, período $s = 7$:

- ▶ **Tendência:** as ondas epidêmicas.
- ▶ **Sazonal:** padrão semanal estável.
- ▶ **Resíduo:** choques irregulares.

O **log** estabiliza a variância (sazonalidade multiplicativa).

Estacionariedade

Estacionariedade fraca

Média, variância e autocovariâncias **não dependem do tempo**:

$$\mathbb{E}[y_t] = \mu, \text{Var}(y_t) = \sigma^2, \text{Cov}(y_t, y_{t+k}) = \gamma_k.$$


É **pré-requisito** para a modelagem ARMA.

- ▶ **ADF**: H_0 = raiz unitária (não estacionária).
- ▶ **KPSS**: H_0 = estacionária (hipóteses trocadas).

Resultados (SP)

Em nível: ADF $p = 0,002$ vs. KPSS $p = 0,044$ — **divergem** (a sazonalidade confunde os testes).

Após 1ª diferença: ADF $p < 0,001 \Rightarrow$ **estacionária**.

The background of the slide is black and features several stylized virus particles. Each particle is a dark gray circle with a lighter gray inner circle and a ring of small red dots representing spikes. They are scattered across the slide, with some partially cut off by the edges.

Regressão linear simples

Regressão linear simples: o modelo de tendência

Ajustamos uma **reta** à série em função do tempo:

$$y_t = \beta_0 + \beta_1 t + \varepsilon_t$$

Estimação por **mínimos quadrados** (MQO):


$$\hat{\beta}_1 = \frac{\sum_t (t - \bar{t})(y_t - \bar{y})}{\sum_t (t - \bar{t})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{t}$$

Qualidade do ajuste:

$$R^2 = 1 - \frac{\sum_t (y_t - \hat{y}_t)^2}{\sum_t (y_t - \bar{y})^2} \in [0, 1]$$

Mesma base da disciplina de origem: `scipy.stats.linregress` e `statsmodels.OLS`.

Regressão linear: tendência de casos em SP



Janela 01/11/2020–31/03/2021
($n = 151$):

$$\widehat{\text{casos}} = 3469 + 73,3 t$$

- ▶ Tendência **+73 casos/dia** ($p < 10^{-12}$).
- ▶ IC 95%: [55,3; 91,2].
- ▶ $R^2 = \mathbf{0,30}$ (diário).
- ▶ $R^2 = \mathbf{0,77}$ (média móvel 7d).

■ Por que a regressão simples não basta

O MQO supõe erros **independentes** — o que quase nunca vale em séries temporais. A estatística de **Durbin-Watson**:

$$d = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_t e_t^2} \approx 2(1 - \hat{\rho}_1)$$



$d \approx 2$: sem autocorrelação. Aqui $d = 1,40$.

Consequência

Resíduos **autocorrelacionados** (padrão semanal) $\Rightarrow$ erros-padrão subestimados e previsões pobres.

Conclusão: precisamos de modelos que tratem a **dependência temporal**. *É o resto do seminário.*

Ponte com Cálculo Numérico: linearização



No início de uma onda o crescimento é **exponencial**, $y = A e^{kt}$. O logaritmo **lineariza**:

$$\ln y = \ln A + k t$$

e aplicamos regressão linear em $(t, \ln y)$.

Ômicron: $k = 0,174/\text{dia}$, $R^2 = 0,59$, duplicação $\approx 4,0$ dias.

The background of the slide is black and features several stylized virus particles. Each particle is a dark gray circle with a lighter gray inner circle and a ring of small red dots around its perimeter, connected by thin lines. These particles are scattered across the slide, with some partially cut off by the edges.

Alisamento exponencial

Alisamento exponencial simples (SES)

A previsão é uma **média ponderada** do passado, com pesos que **decaem exponencialmente**:

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha)\hat{y}_t, \quad 0 < \alpha < 1$$

Forma de componente de nível: $\ell_t = \alpha y_t + (1 - \alpha)\ell_{t-1}$, $\hat{y}_{t+h} = \ell_t$.

- ▶ $\alpha \rightarrow 1$: reage rápido; $\alpha \rightarrow 0$: muito suave.
- ▶ Adequado a séries **sem tendência nem sazonalidade** — precisamos estender.

■ Holt e Holt-Winters

Holt (tendência)

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1}), \quad b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}, \quad \hat{y}_{t+h} = \ell_t + h b_t$$

Holt-Winters (tendência + sazonalidade s_t , período m)

$$s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}, \quad \hat{y}_{t+h} = \ell_t + h b_t + s_{t+h-m(\lfloor (h-1)/m \rfloor + 1)}$$


Usamos **tendência amortecida** e modelamos em $\log(1 + \text{casos})$.

Alisamento exponencial: previsão de 28 dias



Modelo	α	RMSE
SES	0,23	725
Holt	0,14	709
Holt-Winters	0,24	498

Só o **Holt-Winters** capta o padrão semanal — reduz o erro em $\sim 30\%$. A sazonalidade é a estrutura **dominante**.

The background is dark gray with several stylized virus particles. Each particle consists of a dark gray circle with a lighter gray inner circle, and a ring of small red dots representing spikes. These particles are scattered across the frame, with some partially cut off by the edges.

Autocorrelação: ACF e PACF

■ Ruído branco, autocovariância e ACF

Ruído branco

ε_t i.i.d., média 0, variância σ^2 , sem autocorrelação — o "tijolo" dos modelos.

ACF — correlação com a defasagem k :


$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)}$$

PACF ϕ_{kk} — correlação entre y_t e y_{t-k} **removido** o efeito das defasagens intermediárias.


O **correlograma** (ACF/PACF) é a principal ferramenta de identificação.

ACF e PACF da série de SP


ACF — log(casos) em NÍVEL (decai devagar → não estacionária)




PACF — log(casos) em nível



ACF — 1ª diferença (picos em 7,14,21 → sazonal)




PACF — 1ª diferença



The background is dark gray with several stylized virus particles. Each particle consists of a dark gray circle with a lighter gray inner circle, and a ring of small red dots representing spikes or surface proteins.

Modelos de médias móveis (MA)

■ Filtro de média móvel $\neq$ modelo MA(q)



Cuidado com a ambiguidade!

- ▶ **Filtro** de média móvel: técnica *descritiva* de suavização (remove o ruído semanal).
- ▶ **Modelo** MA(q): processo *estocástico* baseado em **choques** passados.

Modelo de médias móveis MA(q)

$$y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} = \mu + \theta(\mathcal{B}) \varepsilon_t$$

$\mathcal{B}$ é o **operador de retardo** ($\mathcal{B}y_t = y_{t-1}$); $\theta(\mathcal{B}) = 1 + \theta_1 \mathcal{B} + \cdots + \theta_q \mathcal{B}^q$.

- ▶ Combinação linear de **choques aleatórios** — "memória" de tamanho q .
- ▶ É **sempre estacionário**.
- ▶ **Identificação**: a **ACF** corta após a defasagem q ; a **PACF** decai gradualmente.

The background of the slide is black and features several stylized virus particles. These particles are represented as dark gray circles with a lighter gray inner circle, and they have small red dots connected by thin lines to their periphery, resembling spikes or surface proteins. They are scattered across the slide, with some partially cut off by the edges.

Modelos autorregresivos (AR)

Modelo autorregressivo AR(p)

y_t é regredido sobre seus **próprios valores passados**:

$$y_t = c + \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \varepsilon_t \iff \phi(\mathcal{B}) y_t = c + \varepsilon_t$$

- ▶ **Estacionariedade**: raízes de $\phi(\mathcal{B}) = 0$ **fora do círculo unitário** (AR(1): $|\phi_1| < 1$).
- ▶ **Identificação** (simétrica ao MA): a **PACF** corta após p ; a ACF decai gradualmente.

Dualidade: AR(p) estacionário = MA(∞); MA(q) invertível = AR(∞). Por isso combinamos os dois.

The background of the slide is black and features several stylized virus particles. These particles are represented as dark gray circles with a lighter gray concentric circle inside. Small red dots, representing spikes or surface proteins, are attached to the outer edge of each virus particle by thin red lines. The virus particles are scattered across the slide, with some partially visible at the edges.

Modelos ARMA

ARMA(p,q): juntando AR e MA

$$\phi(\mathcal{B}) y_t = c + \theta(\mathcal{B}) \varepsilon_t$$

Identificação (Box–Jenkins):

- ▶ ACF e PACF **ambas decaem** $\Rightarrow$ ARMA.
- ▶ Ordens (p, q) por **parcimônia** e critérios de informação:

$$\text{AIC} = -2 \ln L + 2k, \quad \text{BIC} = -2 \ln L + k \ln n$$

Ajustes ilustrativos (série diferenciada):

Modelo	AIC
AR(7)	2373
MA(7)	2407
ARMA(2,2)	2439

A componente em *lag* 7 pede estrutura **sazonal** (SARIMA).

The background of the slide is black and features several stylized virus particles. Each particle is a dark gray circle with a lighter gray concentric circle inside, and a ring of small red dots around the perimeter, connected by thin lines. There are five such particles: one in the top left, one in the top center, one in the top right, one in the bottom left, and one in the bottom right.

Modelos ARIMA

Do ARMA ao ARIMA: a integração (I)

Quando a série **não é estacionária**, aplicamos a **diferenciação**

$\Delta y_t = y_t - y_{t-1} = (1 - \mathcal{B})y_t$. Diferenciando d vezes:

$$\phi(\mathcal{B})(1 - \mathcal{B})^d y_t = c + \theta(\mathcal{B})\varepsilon_t$$


- ▶ $d = \text{n}^\circ$ de diferenças para estacionarizar (em geral 1 ou 2).
- ▶ ARIMA = ARMA sobre a série **diferenciada**.
- ▶ Modelar $\log(1 + y_t)$ **estabiliza a variância** antes de diferenciar.

Metodologia de Box-Jenkins

1. **Identificação** — log + diferenciação (d); ler ACF/PACF para (p, q) .
2. **Estimação** — parâmetros por máxima verossimilhança.
3. **Diagnóstico** — resíduos devem ser **ruído branco** (Ljung-Box).
4. **Previsão** — $\hat{y}_{n+h}$ com intervalos de confiança.

$$Q_{LB} = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k} \sim \chi_{m-(p+q)}^2 \quad (H_0 : \text{resíduos não correlacionados})$$


Diagnóstico de resíduos do modelo ajustado



Resíduos do modelo sazonal:

- ▶ sem padrão temporal;
- ▶ ACF dentro das bandas;
- ▶ histograma/QQ $\approx$ normal.

Ljung-Box (lag 14): $p = 0,59$
⇒ ruído branco — modelo adequado.

The background of the slide is black and features several stylized virus particles. These particles are represented as dark gray circles with numerous small red dots attached to their perimeters by thin lines, resembling spikes or surface proteins. They are scattered across the slide, with some partially visible at the edges.

Sazonalidade: SARMA e SARIMA

■ Incorporando a sazonalidade: SARMA e SARIMA


Adicionamos operadores **sazonais** de período s (aqui $s = 7$):

$$\Phi_P(\mathcal{B}^s) \phi_p(\mathcal{B}) (1 - \mathcal{B})^d (1 - \mathcal{B}^s)^D y_t = \Theta_Q(\mathcal{B}^s) \theta_q(\mathcal{B}) \varepsilon_t$$

$$\text{SARIMA}(p, d, q)(P, D, Q)_s$$

- ▶ (p, d, q) : parte **não sazonal**; (P, D, Q) : parte **sazonal**.
- ▶ $(1 - \mathcal{B}^s)^D$: **diferença sazonal** ($y_t - y_{t-7}$).
- ▶ **SARMA**: caso com $d = D = 0$. Usamos **SARIMA**(2, 1, 2)(1, 1, 1)₇.

ARIMA vs. SARIMA: o ganho da sazonalidade



Modelo	AIC	RMSE
ARIMA(2, 1, 2)	1877	714
SARIMA	1663	567

O ARIMA prevê uma **linha plana**;
o SARIMA reproduz o **zigue-zague semanal** (−20% no erro).
Faixa = IC 95%.

The background of the slide is dark gray and features several stylized virus particles. Each particle is a dark gray circle with a lighter gray inner circle and is surrounded by small red dots connected by thin lines, representing spikes or surface proteins. These particles are scattered across the slide, with some partially visible at the edges.

Variáveis exógenas: SARIMAX


Modelagem com variáveis exógenas (SARIMAX)

Regressão dinâmica: regressores externos $x_{j,t}$ + erro com estrutura SARIMA:

$$y_t = \sum_j \beta_j x_{j,t} + n_t, \quad n_t \sim \text{SARIMA}(p, d, q)(P, D, Q)_s$$

- ▶ Une o **poder explicativo** de covariáveis à **autocorrelação** do erro.
- ▶ Exemplos: feriados, temperatura, mobilidade, outra série relacionada.
- ▶ **Atenção:** para prever é preciso conhecer o **caminho futuro** das exógenas.

Exógena 1 – feriados: quando não ajuda




Dummy de **feriados nacionais** como exógena:

- ▶ coeficiente $-0,5\%$ — efeito **pequeno**;
- ▶ RMSE igual ao SARIMA (566 vs 567).

Lição: a sazonalidade já capta o calendário. Exógena só agrega se trazer **informação nova**.


Exógena 2 – casos → óbitos: quando ajuda



Prever **óbitos** usando o nº de **casos** como exógena (corr. log-log = 0,86):


	AIC	RMSE
SARIMA	1257	79,6
SARIMAX	1011	74,2

—246 no **AIC** e —7% no **RMSE**: a covariável carrega **informação real**.

The background of the slide is dark gray and features several stylized virus particles. Each particle is a dark gray circle with a lighter gray inner circle and a ring of small red dots representing spikes. They are scattered across the slide, with some partially cut off by the edges.

Comparação e conclusões

Comparação geral dos modelos



Modelo	RMSE	MAPE
SES	725	80%
Holt	709	83%
Holt-Winters	498	40%
ARIMA(2, 1, 2)	714	79%
SARIMA	567	40%
SARIMAX	566	40%

Os modelos **sazonais** dominam. Sem modelo universal: vale a **parcimônia**.

Conclusões

- ▶ A **regressão linear** acha a tendência, mas seus resíduos autocorrelacionados ($d = 1,40$) exigem modelos próprios de séries temporais.
- ▶ **Holt–Winters** e **SARIMA** capturam a sazonalidade semanal e foram os melhores (−30% de erro).
- ▶ **ACF/PACF** guiam $(p, d, q)(P, D, Q)_s$; o **Ljung–Box** confirma a adequação.
- ▶ Variáveis **exógenas** (SARIMAX) ajudam só quando trazem informação nova — feriados vs. casos→óbitos.

Limitações dos dados: subnotificação, atraso de divulgação e revisões retroativas geram a sazonalidade semanal e dificultam previsões longas.

Reprodutibilidade

Tudo é reproduzível em Python (numpy, pandas, statsmodels, matplotlib):

```
# 1) constrói a série diária a partir do dataset bruto  
python src/preparar_dados.py --uf SP
```

```
# 2) roda toda a análise e gera figuras + resultados.json  
python src/analise_series_temporais.py
```

Os números do seminário vêm de dados/resultados.json.

Referências

- ▶ BOX, JENKINS, REINSEL, LJUNG. *Time Series Analysis: Forecasting and Control*. 5ª ed. Wiley, 2015.
- ▶ MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais*. 3ª ed. Blucher, 2018.
- ▶ HYNDMAN, R. J.; ATHANASOPOULOS, G. *Forecasting: Principles and Practice*. 3ª ed. OTexts, 2021.
- ▶ BROCKWELL, P. J.; DAVIS, R. A. *Introduction to Time Series and Forecasting*. 3ª ed. Springer, 2016.
- ▶ **Dados:** DATASUS / Brasil.IO — brasil.io/dataset/covid19.

The background of the slide is black and features several stylized virus particles. Each particle is a dark grey circle with a lighter grey concentric circle inside, and a ring of small red dots around the outer edge, representing spikes. These particles are scattered across the slide, with some partially visible at the edges.

Obrigado!

Perguntas?